

## 基于可穿戴设备的跌倒检测算法综述

忽丽莎<sup>1</sup>, 王素贞<sup>1</sup>, 陈益强<sup>2</sup>, 高晨龙<sup>2</sup>, 胡春雨<sup>2</sup>, 蒋鑫龙<sup>2</sup>, 陈振宇<sup>3</sup>, 高兴宇<sup>4</sup>

(1. 河北经贸大学 信息技术学院, 石家庄 050061; 2. 中国科学院计算技术研究所, 北京 100190;

3. 中国电力科学研究院, 北京 100192; 4. 中国科学院微电子研究所, 北京 100029)

**摘 要:** 综述 2013-2018 年基于穿戴式惯性传感器的跌倒检测研究工作. 从跌倒的定义出发, 阐述常规跌倒行为的几种状态、跌倒的分类方式及其类别. 以可穿戴跌倒检测系统框架为基础, 依次从数据采集、预处理、特征提取、模型构建等角度分别展开介绍当前的研究工作. 归纳用于跌倒检测性能评估的一系列技术指标, 展示 9 个跌倒检测的公开数据集, 以及当前跌倒检测研究在这些数据集上的检测精度. 旨在为后续开展可穿戴跌倒检测工作提供借鉴与参考.

**关键词:** 可穿戴设备; 跌倒检测; 健康监护; 机器学习

**中图分类号:** TP 181      **文献标志码:** A      **文章编号:** 1008-973X(2018)09-0001-01

## Fall detection algorithms based on wearable device: a review

HU Li-sha<sup>1</sup>, WANG Su-zhen<sup>1</sup>, CHEN Yi-qiang<sup>2</sup>, GAO Chen-long<sup>2</sup>, HU Chun-yu<sup>2</sup>,  
JIANG Xin-long<sup>2</sup>, CHEN Zhen-yu<sup>3</sup>, GAO Xing-yu<sup>4</sup>

(1. Institute of Information Technology, Hebei University of Economics and Business, Shijiazhuang 050061, China;

2. Institute of Computing Technology, Chinese Academy of Sciences, Beijing 100190, China;

3. China Electric Power Research Institute, Beijing 100192, China; 4. Institute of  
Microelectronics, Chinese Academy of Sciences, Beijing 100029, China)

**Abstract:** Fall detection methods based on wearable inertial devices were elaborated from 2013 to 2018. First of all, the definition of fall, conventional phases contained within a fall, classification and categories of falls were fully introduced. Secondly, current research works were introduced with respect to modules such as data collection, preprocessing, feature extraction and model construction of the wearable fall detection system framework. A series of widely-used technical criteria were induced for evaluating the performance of fall detection methods. At last, nine public fall detection datasets were described, as well as the predictive performance based on those datasets, which is helpful for future research in fall detection research area.

**Key words:** wearable device; fall detection; health care; machine learning

随着医疗技术的发展与人民生活水平的提高, 人类社会日益步入老龄化阶段. 如何实现健康老龄化、提高老年人的生活质量是全社会亟待解决的难题. 老年人在日常生活中由于平衡能力

差、身体素质弱等因素, 极易发生跌倒. 跌倒后如不能得到及时救治, 将会给老人带来极其严重的伤害, 甚至危及生命. 因此, 跌倒检测是面向老年人监护的一项重要研究内容.

收稿日期: 2017-11-10.

网址: [www.zjujournals.com/eng/fileup/HTML/20180X00X.htm](http://www.zjujournals.com/eng/fileup/HTML/20180X00X.htm)

**基金项目:** 国家自然科学基金资助项目(61702491); 国家电网公司总部科技资助项目(5442DZ170019); 河北省高等学校科学技术研究资助项目(QN2018116、QN2018105、ZD2018205); 河北经贸大学校内科研基金资助项目(2016KYZ05).

**作者简介:** 忽丽莎(1986—), 女, 讲师, 博士, 从事机器学习、可穿戴计算研究. [orcid.org/0000-0002-1810-2430](http://orcid.org/0000-0002-1810-2430). E-mail: [hulisha@heuet.edu.cn](mailto:hulisha@heuet.edu.cn)  
通信联系人: 陈益强, 男, 研究员, 博士. [orcid.org/0000-0002-8407-0780](http://orcid.org/0000-0002-8407-0780). E-mail: [yqchen@ict.ac.cn](mailto:yqchen@ict.ac.cn)

随着微型传感器件的升级和人工智能技术的发展, 纷繁众多的可穿戴设备日益涌入人们的日常生活, 广泛应用于健康监护、运动保健等领域. 可穿戴行为识别利用设备内嵌的传感器采集数据, 根据数据识别用户的日常行为. 可穿戴行为识别对提高老年人监护水平、应对老龄化社会挑战等具有重要的研究价值.

跌倒作为一种典型的异常行为, 具有其自身的特点. 凯洛格国际工作组 (Kellogg International Working Group) 将跌倒定义为“无意地摔在地面或更低的平面上, 但不包括遭到暴力撞击, 意识丧失, 中风或癫痫发作所致的行为”<sup>[1]</sup>. 此外, 跌倒还可以解释为“因疏忽意外导致身体接触到地面、地板或者其他较低的位置”<sup>[2]</sup>. 与可穿戴行为识别相比, 基于可穿戴设备的跌倒检测存在一系列独特的问题和挑战.

近年来, 众多学者在基于穿戴式惯性传感器的跌倒检测研究方面做了大量工作. 在参阅近几年研究工作的基础上, 本文从多个角度对其进行介绍. 第1章介绍跌倒过程和分类方式; 第2章介绍可穿戴跌倒检测方法在跌倒检测系统中各模块的处理方式; 第3章介绍衡量跌倒检测算法性能优劣的代表性评价指标; 第4章介绍用于跌倒检测算法研究的公开数据集及相关工作; 第5章将本文工作与其他代表性的跌倒检测综述文章进行对比; 第6章总结当前面临的一些挑战, 并展望未来的研究.

## 1 跌倒过程及其分类

### 1.1 跌倒过程

跌倒通常包含“失重”、“撞击”、“静止”、“朝向变化”和“时间约束”5种状态. 如图1所示, 其中  $t$  为时间,  $a$  为加速度,  $g=9.8 \text{ m/s}^2$ , 为重力加速度. 下面将针对这几种状态分别开展介绍.

1) 失重 (Weightless): 跌倒刚开始时, 人的双脚会逐渐离开地面并在重力的作用下自由向下坠落, 人此时处于失重状态. 由于仅受重力作用, 身体在与地面发生撞击之前速度会逐渐增大至某个最大值. 在这一失重过程中, 加速度将由重力加速度  $g$  逐渐下降并趋于0.

2) 撞击 (Impact): 撞击发生前, 身体向下的速度达到最大, 撞击发生时与地面 (或其他物体) 突然发生碰撞, 速度骤减为零, 此时加速度会迅速




图 1 一次跌倒行为通常包含的几种状态

Fig. 1 Typical phases contained during one fall activity

增加并生成一个明显的峰值.

3) 静止 (Motionless): 一般情形下, 人在跌倒后很短的一段时间内会处于一种相对静止的状态, 无论跌倒是否造成严重的影响. 人体加速度在这一阶段会呈现一种相对平稳的趋势.

4) 朝向变化 (Orientation change): 通常跌倒后人身体的朝向会与跌倒前有所差异, 因此跌倒经常伴随着人体朝向的改变. 这一现象可由图1中加速度的一个或几个轴取值符号的变化情况看出.

5) 时间约束 (Time interval): 一般来说, 上述几种状态通常会在一定的时间间隔内按先后顺序依次发生.

### 1.2 跌倒分类

(1) 基于跌倒方向的分类. 跌倒行为最常用的分类方式是根据跌倒的方向进行划分, 最常见的分类方式如下: 前向跌倒、后向跌倒和侧向跌倒 (包含左右两侧). 许多研究工作采集这3种类型的跌倒数据进行跌倒检测与分析<sup>[3-7]</sup>. 此外, 一些研究学者在上述3类的基础上添加了一些其他的类别, 例如: 臀部/膝盖先着地<sup>[8]</sup>、行走/站立过程中的前向/后向/侧向跌倒<sup>[9]</sup>、扶墙缓慢滑倒<sup>[10-11]</sup>等, 从而使跌倒行为的分析更为全面.

(2) 基于情境的分类. 跌倒行为的另一种分类方式是依据情境 (跌倒动作发生时的场景信息) 进行划分. 例如可将跌倒划分为从床/椅子/支撑物上跌倒<sup>[12-13]</sup>、行走/上楼梯/下楼梯时跌倒<sup>[14]</sup>、平躺式/前跪式/落座式跌倒<sup>[15]</sup>、滑倒/绊倒/昏倒/撞倒/失足跌倒<sup>[16-17]</sup>、弯腰时/弯腰恢复时跌倒<sup>[18]</sup>、二次跌倒 (跌倒起来后再次跌倒)<sup>[19-20]</sup>等多种情况, 旨在根据多种现实情境真实反映用户的多样化跌倒行为.

跌倒的分类方式正朝着多尺度、细粒度的方向发展. 不断细化和日益完善的分类方式使跌倒检测技术的发展更加贴近实际应用的需求.

## 2 可穿戴跌倒检测现状分析

基于穿戴式惯性传感器的跌倒检测系统框架如图2所示,包括训练(实线箭头)和测试(虚线箭头)两个过程.训练过程中,采集的跌倒与非跌倒原始数据首先经过预处理和特征提取2个模块生成样本集,用于训练跌倒检测模型.在预测阶段,原始数据经过相同的预处理和特征提取步骤生成测试样本,由跌倒检测模型判断是否发生了跌倒.一旦检测到发生了跌倒,则立即触发报警操作.下面将详细介绍已有工作针对以上几个模块的研究结果.

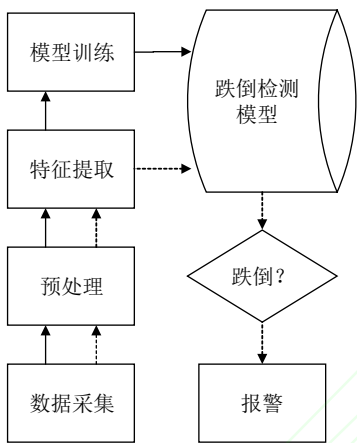


图2 可穿戴跌倒检测系统框架

Fig. 2 Wearable fall detection system framework

### 2.1 数据采集

**2.1.1 加速度计** 利用穿戴在用户身上的加速度计可以有效捕捉跌倒的失重和撞击2个状态.许多研究工作基于采集的腰部加速度数据检测用户是否发生了跌倒<sup>[4, 19, 21-25]</sup>;腰部是最常用的设备穿戴位置之一,原因在于用户可将设备固定在腰带上,有助于减少设备穿戴位置对用户的侵扰.根据设备放置在腰部的不同位置,以上工作还可进一步细分为:基于腰部前侧中部<sup>[19, 23]</sup>、腰部前侧左部<sup>[21]</sup>、腰部右侧<sup>[4, 22]</sup>、腰部后侧中部<sup>[24]</sup>等的跌倒检测(见图3).

此外,以手表或手环的形式将加速度计穿戴于腕部,也可以减少设备对用户的干扰<sup>[14, 26-28]</sup>.其他一些工作则将设备穿戴于臀部<sup>[29]</sup>、胸部<sup>[30-31]</sup>、锁骨<sup>[32]</sup>、肩部<sup>[33]</sup>、膝部<sup>[6]</sup>或身体的多个部位.

鉴于上述多样化的穿戴位置,一些研究学者分析了在利用单个加速度计进行跌倒检测时,不同的穿戴位置对检测结果性能的影响.Xie等<sup>[33]</sup>发




图3 数据采集设备安装位置

Fig. 3 Installation positions of data collection device

现将加速度计安装在腰部、胸部或肩部,可以获得类似的检测精度.

利用加速度计检测跌倒,主要是检测跌倒过程的一个或几个状态,例如许多研究工作中将满足某种条件的加速度峰值识别为撞击动作,进而判别发生了跌倒.当加速度计的穿戴位置或朝向不同时,采集的加速度数据的差异会很大,例如跌倒引起的腕部和腰部的峰值差异十分明显.如何针对不同穿戴位置或朝向的设备设计合适的跌倒检测模型是基于加速度计的跌倒检测方法的技术难点之一.此外,一些非跌倒行为也会产生较高的峰值例如手在自由摆动时突然撞向某个物体,此时腕部的加速度也会生成一个明显的波峰,这给构建低误警的跌倒检测模型带来一定的挑战.

**2.1.2 加速度计+陀螺仪** 将陀螺仪与加速度计进行结合,可在识别失重、撞击状态的同时分析用户身体朝向或姿势的变化,从而进一步判断是否真的发生了跌倒.一些研究工作通过将加速度计和陀螺仪穿戴在用户的腰部<sup>[2, 7, 16, 34-35]</sup>、腕部<sup>[3]</sup>、胸部<sup>[5]</sup>、背部<sup>[35]</sup>、颈部<sup>[36]</sup>或多个部位<sup>[18]</sup>来检测跌倒.

同理,将加速度计和陀螺仪穿戴在不同位置,生成的跌倒检测方法的性能也不尽相同.Zhang等<sup>[4]</sup>在分析了胸部、腰部、大腿部、小腿部位4个位置的数据后,发现腰部是衡量不同行为特性的最佳位置;Shi等<sup>[18]</sup>将设备同时安装在用户的腿部、脚部、上肢、腕部、腰部、头部、背部等14个部位,发现单一位置中腰部的效果最好,腰部与脚部数据的结合可进一步提高跌倒与非跌倒的区分度.

结合加速度计和陀螺仪的跌倒检测,则是在单纯识别“失重”或“撞击”动作的同时进一步分析



用户身体朝向的变化情况,利用先验知识将与跌倒无关的动作排除,可有效降低将“疑似跌倒”的非跌倒行为误判为“跌倒”的风险.已有工作主要针对加速度计和陀螺仪的采集数据分别进行特征提取,再将数据在特征层或分类器层进行融合.基于深度学习框架将异构多模数据在数据层开展深入的融合与特征学习,对构建高精度的跌倒检测模型具有十分重要的研究意义.

**2.1.3 加速度计及其他** 此外加速度计还可与陀螺仪和磁力计<sup>[34]</sup>、RFID<sup>[8]</sup>、气压计<sup>[9]</sup>、肌电<sup>[37]</sup>等结合以检测跌倒.一些跌倒检测研究工作将九轴传感器(三轴加速度计+三轴陀螺仪+三轴磁力计)穿戴在用户的腰部<sup>[11]</sup>、腕部<sup>[38]</sup>、踝部<sup>[10]</sup>和胸部<sup>[34]</sup>.Sabatini等<sup>[9]</sup>利用穿戴在用户背部的加速度计、陀螺仪和气压计检测跌倒.

第2.1.1节和2.1.2节主要利用加速度计、陀螺仪等惯性传感器分析跌倒行为本身的运动特点,将惯性传感器与其他类型的传感器结合,可利用跌倒行为发生时的情境信息辅助进行检测跌倒,例如:依据RFID识别跌倒时用户交互的物体设备、利用气压计获取跌倒前后用户重心的变化情况.用户的生活模式存在个性化特点,采集的情境信息也是动态变化的.因此,合理利用情境信息并将其与运动信息进行有效结合,构建用户个性化且性能鲁棒的跌倒检测模型也是当前的一个研究热点.

## 2.2 数据预处理

为了降低跌倒检测的误报警率,避免原始数据中的噪音等对检测结果的影响,新采集的传感器数据通常需要经由校准、规范化、去噪、轴合成等预处理操作对原始数据进行“清洗”后再进行后期的特征提取等操作.本文重点对轴合成这一预处理技术展开介绍.

第2.1节采集的原始数据通常是包含多个维度(三轴加速度、三轴角速度等)的时间序列信号,即每一时刻存在多个轴的读数.一些方法直接通过分析每个单轴的原始数据的特性识别是否为跌倒.例如,Xie等<sup>[33]</sup>根据三轴( $X/Y/Z$ )加速度的任意一轴读数在某个时间段内持续低于某个阈值识别跌倒;Ahn等<sup>[7]</sup>将加速度高于0.8 g且旋转角速度每秒高于30°的行为识别为跌倒;而许多工作首先将多个轴的数据以某种方式进行合成,对合成后数据的特性进行分析.以下是几个常用的轴合成方法.

以加速度计的三轴 $a_x$ 、 $a_y$ 、 $a_z$ 构建三维坐标系,图4展示了一些具有代表性的合成轴在坐标系的表示,下面将详细展开介绍.




图4 基于三轴加速度计坐标的轴合成方法

Fig. 4 Axis synthesis methods based on coordinates of triaxial accelerometer

1) 矢量和 (sum vector magnitude)/均方根 (root mean square, RMS):

$$a_{\text{RMS}}(t) = \sqrt{a_x(t)^2 + a_y(t)^2 + a_z(t)^2}. \quad (1)$$

其中, $a_x(t)$ 、 $a_y(t)$ 、 $a_z(t)$ 为 $t$ 时刻加速度计在 $X$ 、 $Y$ 或 $Z$ 轴方向的读数.均方根常用于衡量设备朝向不确定时的加速度值<sup>[5, 19, 22, 24, 26, 28]</sup>.

2) 水平 (Horizontal) & 垂直 (Vertical):

$$\left. \begin{aligned} a_{\text{hor}}(t) &= \sqrt{a_x(t)^2 + a_y(t)^2}, \\ a_{\text{ver}}(t) &= a_z(t). \end{aligned} \right\} \quad (2)$$

当 $Z$ 轴与重力轴平行时, $a_{\text{hor}}(t)$ 衡量水平方向的加速度, $a_{\text{ver}}(t)$ 衡量垂直方向的加速度<sup>[39]</sup>.

3) 身体倾斜角 (body tilt angle, BTA)

$$b_{\text{BTA}}(t) = \arccos \frac{a_y(t)}{a_{\text{RMS}}(t)}. \quad (3)$$

$b_{\text{BTA}}(t)$ 用于衡量身体相对于重力方向的倾斜程度<sup>[19, 24]</sup>.

4) 微分:

$$a_d(t) = \sqrt{d_x(t)^2 + d_y(t)^2 + d_z(t)^2}. \quad (4)$$

其中, $d_x$ 、 $d_y$ 、 $d_z$ 为加速度沿 $X$ 、 $Y$ 、 $Z$ 轴方向的微分,可用于区分用户是否处于某种活跃状态<sup>[31]</sup>.

5) 改进的矢量和 (SVMA&SVMB):

$$\left. \begin{aligned} a_{\text{SVMA}}(t) &= \sqrt{3}a_1(t), \\ a_{\text{SVMB}}(t) &= a_1(t) + (\sqrt{2}-1)\max(a_1(t), a_2(t)) + \\ &\quad (\sqrt{3}-\sqrt{2})\min(a_1(t), a_2(t)). \end{aligned} \right\} \quad (5)$$

其中,将 $a_x(t)$ 、 $a_y(t)$ 、 $a_z(t)$ 按由大到小的顺序排序后记为 $a_1(t)$ 、 $a_2(t)$ 、 $a_3(t)$ 。 $a_{SVMA}$ 用于识别跌倒的撞击过程, $a_{SVMB}$ 识别非垂直方向上跌倒有关的一系列动作。Tran 等<sup>[6]</sup>认为当 $a_{SVMA}>2.8\text{ g}$ 且 $a_{SVMB}>2.5\text{ g}$ 时,发生了跌倒。

6)水平旋转速度:

$$c_{GS}(t) = \sqrt{G_y(t)^2 + G_z(t)^2}. \quad (6)$$

式中: $G_y(t)$ 、 $G_z(t)$ 为 $t$ 时刻陀螺仪在 $Y$ 、 $Z$ 轴方向的读数。当陀螺仪穿戴在腕部且 $X$ 轴与上肢平行时, $c_{GS}$ 可用于衡量腕部的旋转运动情况<sup>[3]</sup>。

预处理工作基于不同的目的有多种预处理方式。以上介绍的是在轴合成方面的一些预处理方式。此外,预处理还包括一些用于消除噪音的均值滤波、中值滤波、卡尔曼滤波方法;数据规范化等多种预处理方法,这里就不再作详细的介绍。

### 2.3 特征提取

预处理后的时间序列数据利用滑动窗口机制被分割成一系列窗口,每个窗口包含固定个数(由 $n$ 表示)的样本集 $A = \{A_1, A_2, \dots, A_n\}$ 。基于每个窗口中的数据可以提取一些辅助分析信号规律的特征。

以利用三轴加速度计采集的数据为例,经常用于跌倒检测的时频域特征的提取方式见表 1。针对加速度、速度和角速度的各三轴读数,Aziz 等<sup>[16]</sup>通过计算每个窗口中数据的均值和方差来构造 18 维特征;Pierleoni 等<sup>[11]</sup>实验发现跌倒的撞击过程发生时,加速度的均方根不小于 $2.5\text{ g}$ ;Cheng 等<sup>[37]</sup>认为在行为切换时若加速度的幅值大于某个给定的阈值即为一次跌倒。

表 1 中 $A_x = [A_x(1), A_x(2), \dots, A_x(n)]$ ,  $A_y = [A_y(1), A_y(2), \dots, A_y(n)]$ ,  $A_z = [A_z(1), A_z(2), \dots, A_z(n)]$ 表示一个窗口中加速度计在 $X$ 、 $Y$ 、 $Z$ 轴的读数, $C = \{C_1, C_2, \dots, C_n\}$ 是样本集 $A$ 经 FFT 变换后各频率的幅值。

### 2.4 跌倒检测模型

2.4.1 阈值法 阈值法通过比较特征取值与阈值的大小关系,识别是否属于跌倒的某个状态,进而判断当前行为是否为跌倒。第 1.1 节介绍了跌倒一般包含的 5 种状态,根据识别状态个数的不同,现有的阈值法跌倒检测工作可划分为单一状态识别、多种状态识别两大类。

单一状态识别中较为常见的是识别跌倒的“撞击”和“朝向变化”2 种状态<sup>[21, 24-26, 40]</sup>。其中“撞击”状态因包含极其明显的峰值而最具代表性。基

表 1 跌倒检测常用的特征

Tab. 1 Common features utilized for fall detection

特征	描述
最大值	$\max(A)$
最小值	$\min(A)$
均值	$\text{mean}(A) = \sum_i A_i / n$
范围	$\text{range}(A) = \max(A) - \min(A)$
方差	$\text{var}(A) = \sum_i (A_i - \text{mean}(A))^2 / n$
标准差	$\text{std}(A) = \sqrt{\text{var}(A)}$
均方根	$\text{rms}(A) = \sqrt{\sum_i A_i^2 / n}$
绝对值	$\text{abs}(A_i) =  A_i $
过零率	信号从正数变成负数或反向的次数
信号幅值面积	$\text{sma}(A) = \frac{1}{T} \left( \int_0^T  A_x  dt + \int_0^T  A_y  dt + \int_0^T  A_z  dt \right)$
相关系数	$\text{cc}(A) = \text{cov}(A_x, A_y) / \text{var}(A_x, A_y)$
四分位数	数值由小到大排列后的第 25%, 50%, 75% 个值
幅度	$\mu(A) = \sum_i C_i / n$
幅值标准差	$\sigma(A) = \frac{1}{n} \sum_i (C_i - \mu)^2$
偏度	$\text{skewness}(A) = \frac{1}{n} \sum_i ((C_i - \mu) / \sigma)^3$
峰度	$\text{kurtosis}(A) = \frac{1}{n} \sum_i ((C_i - \mu) / \sigma)^4 - 3$
谱熵	$\text{spectral-entropy}(A) = -\sum_i C_i \log C_i / \log n$
直流分量	$\text{dc}(A) = C_1$
信息熵	$\text{info-entropy}(A) = -\frac{1}{n\mu} \sum_{i=2}^n C_i \log \frac{C_i}{n\mu}$
谱能量	$\text{spectral-energy}(A) = \frac{1}{n} \sum_{i=2}^n C_i^2$

于此,当利用阈值法通过识别跌倒的一个状态判别是否为跌倒时,通常以识别“撞击”状态为主。关于如何判别当前的数据是否处于“撞击”状态,Beevi 等<sup>[25]</sup>认为窗口中加速度的 range 需大于 std;Phu 等<sup>[21]</sup>则认为 rms 应大于 $1.5\text{ g}$ 。另外一些工作则没有提取任何特征,直接将经过矢量和预处理后高于某个阈值(例如: $2\text{ g}$ <sup>[24]</sup>, $4\text{ g}$ <sup>[26]</sup>)的数据识别为“撞击”状态,进而判定发生了跌倒。单一状态识别的阈值法跌倒检测方法受噪声数据的干扰影响较大。例如当手腕甩动中不小心撞到障碍物时,佩戴于腕部的传感器通常也会生成一个明显的峰值,极易被误判为跌倒的“撞击”状态。结合图 1 中状态之间的相互关系,综合识别包括“撞击”在内的 2 个或多个状态可有效避免上述噪声干扰问题<sup>[3, 5, 28, 33]</sup>。

在利用阈值法仅识别跌倒的多种状态方面,Huynh 等<sup>[5]</sup>将加速度矢量和高于 $1.8\text{ g}$ 同时角速度

矢量和每秒大于  $200^\circ$  的行为判定为跌倒, 综合考虑了跌倒在相同时间内历经的“撞击”状态以及跌倒前后设备朝向的改变情况. Kostopoulos 等<sup>[28]</sup>认为跌倒行为的矢量和先高于某个较大的阈值(例如  $18 \text{ m/s}^2$ ), 之后的  $0.5 \text{ s}$  内又会低于某个较小的阈值(例如  $7 \text{ m/s}^2$ ), 通过识别满足一定“时间约束”条件的“撞击”和“静止”状态, 进而判别是否发生了跌倒.

阈值法将预处理后或简单特征提取后的数据跟阈值进行比较, 计算简单, 预测速度快, 十分适合在资源受限的微型可穿戴设备上长期运行; 不足之处在于阈值选取常依赖于模拟跌倒数据, 当测试数据与训练数据分布差异较大时, 严重影响模型的检测精度, 因此缺乏一定的适用性.

**2.4.2 机器学习法** 如果将跌倒检测看作是一个典型的分类问题, 以跌倒和非跌倒数据组成的训练集为基础, 典型的机器学习算法如支持向量机(SVM)<sup>[16,29]</sup>、决策树(DT)、人工神经网络(ANN)<sup>[35]</sup>、K 近邻(K-NN)<sup>[36]</sup>等, 均可用于构建跌倒检测模型<sup>[4, 8, 18, 31-32]</sup>.

Aziz 等<sup>[16]</sup>分别针对三轴加速度、速度、角速度的数据提取均值与方差特征, 训练 SVM 分类器, 并对比分析了窗口大小和提前时间. Diep 等<sup>[29]</sup>基于三轴加速度计的每轴数据, 利用滑动窗口机制针对每个窗口的时间序列数据统计走向(Direction)的类别及各类别包含的个数, 将三轴中各类别的个数作为特征, 利用 SVM 模型训练并预测跌倒. Nukala 等<sup>[35]</sup>针对三轴加速度计、三轴陀螺仪每轴数据计算 range 生成 6 维特征, 训练 ANN 模型. Jian 等<sup>[36]</sup>基于合成加速度与合成角速度分别计算和, 训练 K-NN 跌倒检测模型.

与基于阈值法的跌倒预测模型类似, 基于 DT 的跌倒检测模型也是一系列的规则组合. 两者的主要区别在于: 前者主要识别跌倒过程中的一个或多个状态, 属于启发式规则; 后者则是数据驱动的归纳总结后得出的结果. 非时间序列的机器学习方法(如: SVM、DT、ANN、K-NN)将跌倒检测看作一个典型的分类问题, 在少量必要的数据预处理和特征提取工作后, 直接使用 SVM、DT 等较为成熟的分类模型, 处理方式十分简单. 其中的多类分类跌倒检测方法将跌倒作为多个行为类别之一, 不同类别之间同等对待; 而一类分类跌倒检测方法则主要关注跌倒这一类, 将所有非跌倒行为类别看作一个整体, 不再加以细分, 极大简化了问题的考虑范围. 与其他机器学

习方法使用黑盒子模型相比, DT 模型的优势之一在于模型的可视化程度和可读性强, 方便理解跌倒检测的具体规则.

鉴于跌倒的各个状态之间存在一定的时序关系(如“失重”状态发生在前、“撞击”状态在后, 见图 1), 一些研究者基于时间序列数据构建跌倒检测模型, 如隐马尔科夫模型(hidden Markov model, HMM)、条件随机域(conditional random field, CRF)等<sup>[23, 39, 41-42]</sup>.

通常假设每种行为类别所包含的时间序列数据是依据相同的数据分布生成的. 模型的训练过程则是为不同行为类别分别构建不同的分布函数. 基于窗口长度为  $1.28 \text{ s}$  的样本序列, Khan 等<sup>[39]</sup>基于每间隔  $16 \text{ ms}$  的原始数据生成一个特征向量, 再按时间排序生成特征向量序列. 根据不同类别的特征向量序列分别构建不同的 HMM 模型, 通过对比多个 HMM 模型的识别结果以检测跌倒.

关于各个模型的性能对比方面, Lisowska 等<sup>[32]</sup>对比了阈值法与 SVM、K-NN、随机森林(random forest, RF)、卷积神经网络(convolutional neural network, CNN)4 种监督学习方法, 结果显示 CNN 的效果最好; 对比了递归神经网络(recurrent neural network, RNN)、一类支持向量机(1SVM)和一类神经网络(1NN)3 种一类分类器, 结果显示 1NN 的效果更好; 对比了 6 种有监督的特征选择与一类分类的结合方法, 结果显示 CNN+1SVM 的效果最好; Wang 等<sup>[23]</sup>基于加速度数据训练 HMM、高斯混合模型(Gaussian mixture model, GMM)模型, 并与 SVM 的性能进行比较, 结果显示 HMM 的效果更好; Li 等<sup>[24]</sup>针对加速度的每轴数据分别提取了均值、方差等 7 种时域特征, 以及经由快速傅里叶变换(fast Fourier transform, FFT)后的能量特征, 训练并对比了 K-NN 和 ANN 跌倒检测模型.

时间序列的机器学习方法(如: HMM、CRF)通常为每种类别分别构建一个模型, 将概率最大的模型预测结果进行输出. 每个模型的构建过程则是充分挖掘了行为在不同阶段的时序关系, 根据跌倒数据学习不同状态之间的转换, 以及状态与观察值之间的概率分布.

### 3 评价标准

现有研究已经提出了大量的可穿戴跌倒检测方法, 如何衡量一个方法的性能优劣程度, 以及



如何将多个不同的方法以公平公正的方式进行比较是构造可穿戴跌倒检测算法的关键. 将跌倒检测作为一个二分类问题(跌倒、非跌倒), 以下介绍一些经常使用的衡量跌倒检测方法性能优劣的技术指标, 其中各符号的含义见表 2.

表 2 技术指标中各符号含义

Tab. 2 Symbol interpretation for technical indicators

预测类别\真实类别	跌倒	非跌倒
跌倒	TP	FN
非跌倒	FP	TN

1) 查准率 (Precision)<sup>[31, 29, 38]</sup>: 模型识别为跌倒的样本集中真正的跌倒样本所占的比重:

$$I_{\text{pre}} = \frac{TP}{TP + FP}. \quad (7)$$

2) 查全率 (Recall)<sup>[31, 29, 38]</sup>/敏感度 (Sensitivity)<sup>[1, 15, 18, 24]</sup>: 跌倒样本集中被模型正确识别为跌倒的样本所占的比重:

$$I_{\text{rec}} = I_{\text{sens}} = \frac{TP}{TP + FN} \quad (8)$$

3) 特异度 (Specificity)<sup>[1, 15, 18, 24]</sup>: 非跌倒样本集中被模型正确识别为非跌倒的样本所占的比重:

$$I_{\text{spec}} = \frac{TN}{TN + FP} \quad (9)$$

4) 误警率 (false alarm rate, FAR)<sup>[39]</sup>: 模型识别为跌倒的样本集中的非跌倒样本所占的比重:

$$I_{\text{FAR}} = \frac{FP}{TP + FP} \quad (10)$$

5) 漏警率 (missing alarm rate, MAR)<sup>[39]</sup>: 跌倒样本集中被模型错误识别为非跌倒的样本所占的比重:

$$I_{\text{MAR}} = \frac{FN}{TP + FN} \quad (11)$$

衡量模型的检测效果, 可同时利用 2 个指标依据不同的侧重点分别评估. 例如: 当分别从“准”和“全”2 个角度衡量模型在“跌倒”数据上的检测性能时, 精度则使用  $I_{\text{pre}}$  和  $I_{\text{rec}}$ , 误差则依据  $I_{\text{FAR}}$  和  $I_{\text{MAR}}$ ;  $I_{\text{sens}}$  和  $I_{\text{spec}}$  组合, 则是从“全”这一角度分别衡量模型在“跌倒”和“非跌倒”2 种类别上的检测精度. 综合考虑  $I_{\text{pre}}$  和  $I_{\text{rec}}$  的取值, 可以使用如下的指标.

6) 精度 (Accuracy): 正确检测的样本占总样本的比例:

$$I_{\text{acc}} = \frac{TP + TN}{TP + FP + TN + FN} \quad (12)$$

7) 几何平均 (geometric mean, GMean)<sup>[39]</sup>: 查准率和召回率的几何平均:

$$I_{\text{GMean}} = \sqrt{I_{\text{pre}} \times I_{\text{rec}}}. \quad (13)$$

8) F 度量因子 (F-Score 或 F-Measure)<sup>[29, 31]</sup>: 查准率和查全率的加权调和平均:

$$I_{\text{F-Score}} = \frac{(\beta^2 + 1) I_{\text{pre}} \times I_{\text{rec}}}{\beta^2 (I_{\text{pre}} + I_{\text{rec}})}. \quad (14)$$

其中,  $\beta$  为非负的参数. 当  $\beta=1$  时,  $I_{\text{F-Score}}$  也可表示为  $I_{\text{F1-Score}}$ .

将组合中的 2 个指标以某种方式进行合并, 可以构建出单一的评估指标, 用于综合衡量模型整体的检测效果.  $I_{\text{GMean}}$  是  $I_{\text{pre}}$  和  $I_{\text{rec}}$  的几何平均值,  $I_{\text{F-Score}}$  是两者的加权调和平均值.  $I_{\text{F-Score}}$  中的参数可看作权衡  $I_{\text{pre}}$  和  $I_{\text{rec}}$  的算数平均和几何平均的权重系数, 可根据具体应用设置不同的取值.  $I_{\text{F1-Score}}$  的取值一般小于  $I_{\text{GMean}}$ .

## 4 公开数据集

在跌倒检测研究工作中, 数据采集过程通常十分复杂且有一定的危险性, 而使用公开的跌倒数据集进行跌倒检测模型搭建, 可节约很多时间和精力. 此外, 公开的数据集还有助于跌倒检测算法的设计与评估. 目前基于可穿戴惯性传感器采集的跌倒检测公开数据集如表 3 所示.

这些公开数据集包含的特点如下: 1) Cogent、DLR、Graz 和 SisFall 数据集的采集设备安装在固定位置, 一定程度上保留了特定行为数据良好的规律性; 而 MobiFall、tFall、Gravity、UMAFall 和 UniMiB 数据集则直接将采集设备放在口袋或背包中, 设备朝向任意, 不受限制, 数据的规律性减弱, 但更贴近于现实的应用场景, 以此数据评估得到的模型识别效果更能拟合模型在现实场景的识别性能. 2) 考虑非跌倒行为的组成情况, Cogent 和 SisFall 数据集中除了包含一些常规的日常行为数据之外, 还专门采集了一些疑似跌倒行为, 可专用于评估跌倒检测模型的识别性能. 3) 与单一的设备穿戴位置相比, Cogent、Gravity、UMAFall 等数据集采集了用户身体多个部位的传感数据, 可用于多个位置协同算法的设计与建模工作.

关于这些公开数据集的详细介绍见文献[52].

表 4 列出了基于以上公开数据集的跌倒检测最新研究成果及准确度. 以 MobiFall 数据集为例, 文献[54]是一种典型的机器学习跌倒检测方法代表. 针对加速度三轴和合成轴分别提取时频域特征共计 43 维, 经由 PCA 对提取的特征降维, 再结合模糊学习和超矩形规则等构建多尺度神经网络. 实现结果显示, 该方法在 MobiFall 数据集上的检测精度优于 SVM、K-NN 和 MLP 模型. 文

献[53]中的跌倒检测算法将 3 个长度为 1 s 的连续窗口中的加速度数据与某个阈值进行比较, 从而判断是否为跌倒. 该算法仅包含单个阈值, 计算十分简单, 可有效应用于现场可编程门阵列. 该方法在 MobiFall 数据集上获得精准检测结果的主要原因在于: 数据预处理的滤波窗口大小, 以及跌倒检测算法中的阈值依赖于预测用户, 阈值的选取是根据不同用户的数据通过离线学习分别获得的.

表 3 利用穿戴式惯性传感器采集的跌倒检测公开数据集

Tab. 3 Public fall detection datasets collected with wearable inertial sensors

名称	传感器及采样率	穿戴位置	采集人数	行为类别个数	文献
MobiFall	加速度计 (200 Hz), 陀螺仪 (87 Hz), 方向传感器 (200Hz)	裤子口袋	24(17 男, 7 女)	13(4 跌倒, 9 非跌倒)	[43]
Cogent	加速度计 (100 Hz), 陀螺仪 (100 Hz)	胸部、腿部	42(36 男, 6 女)	14(6 跌倒, 8 非跌倒)	[44]
DLR	加速度计 (100 Hz), 陀螺仪 (100 Hz), 磁力计 (100 Hz)	腰部	19(11 男, 8 女)	16(1 跌倒, 15 非跌倒)	[45]
tFall	加速度计 (50 Hz)	裤子口袋、手提包	10(7 男, 3 女)	未统计 (8 跌倒, 未统计非跌倒)	[46]
Gravity	加速度计 (25 Hz)	裤子口袋、腕部	2(未指名)	19(12 跌倒, 7 非跌倒)	[47]
Graz	加速度计 (5 Hz), 陀螺仪 (5 Hz)	腰部	5(未指名)	14(4 跌倒, 10 非跌倒)	[48]
UMAFall	加速度计 (200 Hz), 陀螺仪 (200 Hz), 磁力计 (200 Hz)	腰部、腕部、踝部、胸部、裤子口袋	17(10 男, 7 女)	11(3 跌倒, 8 非跌倒)	[49]
SisFall	加速度计 (200 Hz), 陀螺仪 (200 Hz)	腰部	38(19 男, 19 女)	34(15 跌倒, 19 非跌倒)	[50]
UniMiB	加速度计 (50 Hz)	裤子口袋	38(6 男, 24 女)	17(8 跌倒, 9 非跌倒)	[51]

表 4 以跌倒检测公开数据集为基础的最新研究成果及准确度

Tab. 4 Latest research and performance based on public fall detection datasets

数据集	模型	精度/%	年份	文献
MobiFall	阈值法	$I_{\text{sens}}=98.1, I_{\text{spec}}=99.2$	2017	[53]
MobiFall	ANN	$I_{\text{sens}}=97.3, I_{\text{spec}}=98.7$	2017	[54]
MobiFall	HMM	$I_{\text{pre}}=98.8, I_{\text{FAR}}=4.5, I_{\text{GMean}}=96.9$	2014	[55]
Coventry Data	阈值法	$I_{\text{FAR}}=12.6, I_{\text{MAR}}=8.9, I_{\text{pre}}=87.5,$	2017	[56]
Coventry Data	LR	$I_{\text{pre}}=97.2, I_{\text{rec}}=98.1, I_{\text{F-Score}}=97.6$	2017	[57]
DLR	OCNN	$I_{\text{pre}}=81.5, I_{\text{MAR}}=71.9, I_{\text{GMean}}=45.9$	2017	[58]
DLR	HMM	$\text{FDR}=90.8, \text{FAR}=2.1, I_{\text{GMean}}=93.8$	2017	[55]
tFall	SVM	$I_{\text{sens}}=95.3, I_{\text{spec}}=92.6$	2014	[46]
tFall	KDE	$I_{\text{sens}}=97.9, I_{\text{spec}}=96.7$	2017	[59]
Gravity	阈值法	$I_{\text{sens}}=63, I_{\text{spec}}=78, I_{\text{acc}}=68$	2015	[47]
UMAFall	阈值法	$I_{\text{sens}}=96.7, I_{\text{spec}}=86.1$	2016	[49]
SisFall	阈值法	$I_{\text{sens}}=95.54, I_{\text{spec}}=96.38, I_{\text{acc}}=95.96$	2017	[50]
UniMiB	SVM	$I_{\text{acc}}=97.57$	2017	[51]



## 5 讨 论

关于跌倒检测的综述性文章,文献[1]可看作是一篇较早的代表性工作,作者从系统、算法、传感器等角度进行了简单分析,并指出需采用客观的性能评价标准衡量不同系统的性能,提到了2个常用的评价指标.文献[23]将基于可穿戴传感器、音频、视频的跌倒检测系统从度量准则、特征和分类器等角度展开对比.针对每一类中的几个代表性工作详细介绍了其具体的实现方式,并归纳总结了每类方法的优缺点.文献[28]又将每个大类进一步划分为多个小类,针对每一类的相关代表性方法开展介绍.同时在费用消耗、用户干扰性、安装复杂度等方面对每类方法给出了整体的评价.针对基于可穿戴传感器和环境传感器的跌倒检测方法,文献[60]详细列出了设备安装位置、行为类别及协议、特征和相关产品,文献[61]分析了趋势、挑战和面临的问题.文献[62]对跌倒检测和预防系统从模型构造、设计思路、定性评估准则等方面进行了对比.文献[63]重点介绍了基于多传感器融合的跌倒检测方法,认为与仅利用单个传感器的方法相比,利用多个不同或相同类别的传感数据的跌倒检测方法可有效提升识别精度和粒度.

与以上综述性工作不同,本文首先从概念、状态划分、类别等方面进行介绍,多方位多角度地描述“跌倒”这一特殊的异常行为;然后给出可穿戴跌倒检测的系统框架,针对其中的各个模板对比介绍近几年相关工作的具体操作方式,充分展示系统框架中各个模块的实现细节;为客观评估跌倒检测系统的性能优劣归纳总结了一系列常用的评价标准,并在最后展示了几个跌倒检测专用的公开数据集.旨在方便初步涉足该领域的研究学者掌握最新研究动态并快速开展进一步的研究工作.

## 6 结 语

本文介绍了跌倒的定义、分类方法,三大类跌倒检测方法;基于跌倒检测系统框架从多个角度分别介绍了基于可穿戴设备的跌倒检测方法;汇总了衡量算法性能优劣的各项指标并介绍了跌倒检测的公开数据集.

基于可穿戴设备的跌倒检测算法仍存在如下几方面的挑战:

1)轻量级计算.与固定设备或云服务设备相比,可穿戴设备的电池、计算、存储等资源十分受限,这给基于可穿戴设备的算法设计带来了诸多限制.跌倒检测是一项需提供长期、实时、精准服务的应用,如何在不损失精度的前提下有效控制模型的计算和存储消耗,十分关键.

2)现实环境中检测精度的稳定性.当前的跌倒检测模型以离线训练为主,训练数据通常是在固定的实验场景中组织采集的,数据包含的行为类别及表征能力均十分有限.以此为训练数据构建的跌倒检测算法,当面对新用户、新行为、动态变化的环境等诸多因素时,检测精度通常会有不同程度的下滑.如何根据动态的现实环境对算法本身进行自适应调整和修正,提供精准且稳定的个性化跌倒预测服务,也是一个十分有价值的研究点.

### 参考文献 (References):

- [1] NOURY N, FLEURY A, RUMEAU P, et al. Fall detection-principles and methods [C] // **Proceedings of the International Conference on Engineering in Medicine and Biology Society**. Lyon: IEEE, 2007: 1663-1666.
- [2] DECILLIS F, DESIMIO F, GUIDOY F, et al. Fall-detection solution for mobile platforms using accelerometer and gyroscope data [C] // **Proceedings of the International Conference on Engineering in Medicine and Biology Society**. Milan: IEEE, 2015: 3727-3730.
- [3] HSIEH S L, CHEN C C, WU S H, et al. A wrist-worn fall detection system using accelerometers and gyroscopes [C] // **Proceedings of the International Conference on Networking, Sensing and Control**. Miami: IEEE, 2014: 518-523.
- [4] ZHANG J, WANG Y, MA Y, et al. Fall detection with the optimal feature vectors based on support vector machine [C] // **Proceedings of the International Conference on Health Information Science**. Shenzhen: Springer, 2014: 160-166.
- [5] HUYNH Q T, NGUYEN U D, LIEM K T, et al. Detection of activities daily living and falls using combination accelerometer and gyroscope [C] // **Proceedings of the International Conference on Biomedical Engineering in Vietnam**. Vietnam: Springer, 2015: 184-189.
- [6] TRAN T H, CHAO P C P, HSU L C, et al. Design and

- development of a new wireless fall detection module for homecare [J]. **Microsystem Technologies**, 2015, 21(12): 2737–2745.
- [7] AHN S, SHIN I, KIM Y. Pre-impact fall detection using an inertial sensor unit [J]. **Journal of Foot and Ankle Research**, 2014, 7(Suppl 1): A124.
- [8] CHENG S H. An intelligent fall detection system using triaxial accelerometer integrated by active RFID [C] // **Proceedings of International Conference on Machine Learning and Cybernetics**. Lanzhou: IEEE, 2014: 517–522.
- [9] SABATINI A, LIGORIO G, MANNINI A, et al. Prior-to-and post-impact fall detection using inertial and barometric altimeter measurements [J]. **IEEE Transactions on Neural Systems and Rehabilitation Engineering**, 2016, 24(7): 774–783.
- [10] PIERLEONI P, BELL I A, PALMA L, et al. A versatile ankle-mounted fall detection device based on attitude heading systems [C] // **Proceedings of International Conference on Biomedical Circuits and Systems**. Lausanne: IEEE, 2014: 153–156.
- [11] PIERLEONI P, BELL I A, PALMA L, et al. A high reliability wearable device for elderly fall detection [J]. **Sensors Journal**, 2015, 15(8): 4544–4553.
- [12] YU X. Approaches and principles of fall detection for elderly and patient [C] // **Proceedings of International Conference on e-health Networking, Applications and Services**. Singapore: IEEE, 2008: 42–47.
- [13] MUBASHIR M, SHAO L, SEED L. A survey on fall detection: principles and approaches [J]. **Neurocomputing**, 2013, 100: 144–152.
- [14] YUAN J, TAN K K, LEE T H, et al. Power-efficient interrupt-driven algorithms for fall detection and classification of activities of daily living [J]. **Sensors Journal**, 2015, 15(3): 1377–1387.
- [15] GRISALES-FRANCO F M, VARGAS F, OROZCO Á Á, et al. **Fall detection algorithm based on thresholds and residual events** [M]. Iberoamerican Congress on Pattern Recognition. Berlin: Springer, 2015: 575–583.
- [16] AZIZ O, RUSSELL C M, PARK E J, et al. The effect of window size and lead time on pre-impact fall detection accuracy using support vector machine analysis of waist mounted inertial sensor data [C] // **Proceedings of International Conference on Engineering in Medicine and Biology Society**. Chicago: IEEE, 2014: 30–33.
- [17] LEE J K, ROBINOVITCH S N, PARK E J. Inertial sensing-based pre-impact detection of falls involving near-fall scenarios [J]. **IEEE Transactions on Neural Systems and Rehabilitation Engineering**, 2015, 23(2): 258–266.
- [18] SHI G, ZHANG J, DONG C, et al. Fall detection system based on inertial mems sensors: Analysis design and realization [C] // **Proceedings of International Conference on Cyber Technology in Automation, Control, and Intelligent Systems**. Shenyang: IEEE, 2015: 1834–1839.
- [19] REN L, SHI W, YU Z, et al. ALARM: A novel fall detection algorithm based on personalized threshold [C] // **Proceedings of International Conference on E-health Networking, Application & Services**. Boston: IEEE, 2015: 410–415.
- [20] Gjoreski H, Luštrek M, Gams M. Context-based fall detection using inertial and location sensors [C] // **International Joint Conference on Ambient Intelligence**. Berlin Heidelberg: Springer, 2012: 1–16.
- [21] PHU P T, HAI N T, TAM N T. A threshold algorithm in a fall alert system for elderly people [C] // **Proceedings of International Conference on Biomedical Engineering in Vietnam**. Ho Chi Minh City: Springer, 2015: 347–350.
- [22] TAN T D, VAN TINH N. Reliable fall detection system using a 3-DOF accelerometer and cascade posture recognitions [C] // **Proceedings of Annual Summit and Conference on Asia-Pacific Signal and Information Processing Association**. Siem Reap: IEEE, 2014: 1–6.
- [23] WANG J, CHEN R, SUN X, et al. Generative models for automatic recognition of human daily activities from a single triaxial accelerometer [C] // **Proceedings of International Joint Conference on Neural Networks**. Brisbane: IEEE, 2012: 1–6.
- [24] LI C, LIN M, YANG L T, et al. Integrating the enriched feature with machine learning algorithms for human movement and fall detection [J]. **The Journal of Supercomputing**, 2014, 67(3): 854–865.
- [25] BEEVI F H A, PADERSEN C F, WANGNER S, et al. **Lateral fall detection via events in linear prediction residual of acceleration** [M]. Ambient Intelligence-Software and Applications. Berlin: Springer, 2014: 201–208.
- [26] ZHOU C C, TU C L, GAO Y, et al. A low-power, wireless, wrist-worn device for long time heart rate monitoring and fall detection [C] // **Proceedings of**

- International Conference on Orange Technologies**. Xi'an: IEEE, 2014: 33-36.
- [27] ALESIN A, OSANLOU A, MAW S W. A low budget multifunctional wearable device for motion and falls detection [C] // **Proceedings of Russian Conference on Young Researchers in Electrical and Electronic Engineering**. Moscow: IEEE, 2018: 1850-1855.
- [28] KOSTOPOULOS P, NUNES T, SALVI K, et al. F2D: A fall detection system tested with real data from daily life of elderly people [C] // **Proceedings of International Conference on E-health Networking, Application & Services**. Boston: IEEE, 2015: 397-403.
- [29] DIEP N N, PHAM C, PHUONG T M. A classifier-based approach to real-time fall detection using low-cost wearable sensors [C] // **Proceedings of the Fifth Symposium on Information and Communication Technology**. Hanoi: IEEE, 2014: 14-20.
- [30] GIA T N, SARKER V K, TCARENKO I, et al. Energy efficient wearable sensor node for IoT-based fall detection systems [J]. **Microprocessors and Microsystems**, 2018, 56: 34-46.
- [31] QU W, LIN F, WANG A, et al. Evaluation of a low-complexity fall detection algorithm on wearable sensor towards falls and fall-alike activities [C] // **Proceedings of International Conference on Signal Processing in Medicine and Biology Symposium**. Philadelphia: IEEE, 2015: 1-6.
- [32] LISOWSKA A, WHEELER G, INZA V, et al. An evaluation of supervised, novelty-based and hybrid approaches to fall detection using silmee accelerometer data [C] // **Proceedings of International Conference on Computer Vision Workshops**. Santiago: IEEE, 2015: 10-16.
- [33] XIE H, TAO X, YE H, et al. WeCare: an intelligent badge for elderly danger detection and alert [C] // **Proceedings of International Conference on Ubiquitous Intelligence and Computing**. Vietri sul Mare: IEEE, 2013: 224-231.
- [34] LEE J K, ROBINOVITCH S N, PARK E J. Inertial sensing-based pre-impact detection of falls involving near-fall scenarios [J]. **IEEE Transactions on Neural Systems and Rehabilitation Engineering**, 2015, 23(2): 258-266.
- [35] NUKALA B T, SHIBUYA N, RODRIGUEZ A I, et al. A real-time robust fall detection system using a wireless gait analysis sensor and an Artificial Neural Network [C] // **Proceedings of International Conference on Healthcare Innovation**. Seattle: IEEE, 2014: 219-222.
- [36] JIAN H, CHEN H. A portable fall detection and alerting system based on k-NN algorithm and remote medicine [J]. **Communications**, 2015, 12(4): 23-31.
- [37] CHENG J, CHEN X, SHEN M. A framework for daily activity monitoring and fall detection based on surface electromyography and accelerometer signals [J]. **IEEE Journal of Biomedical and Health Informatics**, 2013, 17(1): 38-45.
- [38] LI Z, HUANG A, XU W, et al. Fall perception for elderly care: a fall detection algorithm in smart wristlet mhealth system [C] // **Proceedings of International Conference on Communications**. Sydney: IEEE, 2014: 4270-4274.
- [39] KHAN S S, KARG M E, KULIC D, et al. **X-factor HMMs for detecting falls in the absence of fall-specific training data** [M]. Ambient Assisted Living and Daily Activities. Berlin: Springer, 2014: 1-9.
- [40] LAI C F, CHANG S Y, CHAO H C, et al. Detection of cognitive injured body region using multiple triaxial accelerometers for elderly falling [J]. **Sensors Journal**, 2011, 11(3): 763-770.
- [41] WANG S, ZHANG X. An approach for fall detection of older population based on multi-sensor data fusion [C] // **Proceedings of International Conference on Ubiquitous Robots and Ambient Intelligence**. Goyang: IEEE, 2015: 320-323.
- [42] TONG L, SONG Q, GE Y, et al. HMM-based human fall detection and prediction method using tri-axial accelerometer [J]. **Sensors Journal**, 2013, 13(5): 1849-1856.
- [43] VAVOULAS G, PEDIADITIS M, SPANAKIS E G, et al. The MobiFall dataset: an initial evaluation of fall detection algorithms using smartphones [C] // **Proceedings of International Conference on Bioinformatics and bioengineering**. Chania: IEEE, 2013: 1-4.
- [44] OJETOLA O, GAURA E, BRUSEY J. Data set for fall events and daily activities from inertial sensors [C] // **Proceedings of International Conference on Multimedia Systems**. Brisbane: ACM, 2015: 243-248.
- [45] FRANK K, VERA NADALES M J, ROBERTSON P, et al. Bayesian recognition of motion related activities with inertial sensors [C] // **Proceedings of International Conference Adjunct Papers on Ubiquitous Computing**. Copenhagen: ACM, 2010:



- 445–446.
- [46] MEDRANO C, IGUAL R, PLAZA I, et al. Detecting falls as novelties in acceleration patterns acquired with smartphones [J]. **PloS one**, 2014, 9(4).
- [47] VILARINHO T, FARSHCHIAN B, BAJER D G, et al. A combined smartphone and smartwatch fall detection system [C] // **Proceedings of International Conference on Computer and Information Technology; Ubiquitous Computing and Communications; Dependable, Autonomic and Secure Computing; Pervasive Intelligence and Computing**. Liverpool: IEEE, 2015: 1443–1448.
- [48] WERTNER A, CZECH P, PAMMER-SCHINDLER V. An open labelled dataset for mobile phone sensing based fall detection [C] // **Proceedings of EAI International Conference on Mobile and Ubiquitous Systems: Computing, Networking and Services on EAI International Conference on Mobile and Ubiquitous Systems: Computing, Networking and Services**. Coimbra: ACM, 2015: 277–278.
- [49] CASILARI E, SANTOYO-RAMON J A, CANO-GARCIA J M. Analysis of a smartphone-based architecture with multiple mobility sensors for fall detection [J]. **PloS one**, 2016, 11(12): e0168069.
- [50] SUCERQUIA A, LOPEZ J D, VARGAS-BONILLA J F. SisFall: a fall and movement dataset [J]. **Sensors**, 2017, 17(1): 198.
- [51] MICUCCI D, MOBILIO M, NAPOLETANO P. UniMiB SHAR: a dataset for human activity recognition using acceleration data from smartphones [J]. **Applied Sciences**, 2017, 7(10): 1101.
- [52] CASILARI E, SANTOYO-RAMON J A, CANO-GARCIA J M. Analysis of public datasets for wearable fall detection systems [J]. **Sensors**, 2017, 17(7): 1513.
- [53] SAADEH W, ALTAF M A B, ALTAF M S B. A high accuracy and low latency patient-specific wearable fall detection system [C] // **Proceedings of International Conference on Biomedical & Health Informatics**. Orlando: IEEE, 2017: 441–444.
- [54] JAHANJOO A, TAHAN M N, RASHTI M J. Accurate fall detection using 3-axis accelerometer sensor and MLF algorithm [C] // **Proceedings of International Conference on Pattern Recognition and Image Analysis**. Shahrekord: IEEE, 2017: 90–95.
- [55] KHAN S S, KARG M E, KULIC D, et al. Detecting falls with X-factor hidden Markov models [J]. **Applied Soft Computing**, 2017, 55: 168–177.
- [56] MENG L, MIAO C, LEUNG C. Towards online and personalized daily activity recognition, habit modeling, and anomaly detection for the solitary elderly through unobtrusive sensing [J]. **Multimedia Tools and Applications**, 2017, 76(8): 10779–10799.
- [57] PUTRA I, BRUSEY J, GAURA E, et al. An event-triggered machine learning approach for accelerometer-based fall detection [J]. **Sensors**, 2017, 18(1): 20.
- [58] KHAN S S, TAATI B. Detecting unseen falls from wearable devices using channel-wise ensemble of autoencoders [J]. **Expert Systems with Applications**, 2017, 87: 280–290.
- [59] MEDRANO C, IGUAL R, GARCIA-MAGARINO I, et al. Combining novelty detectors to improve accelerometer-based fall detection [J]. **Medical & Biological Engineering & Computing**, 2017, 55(10): 1849–1858.
- [60] NATTHAPON P, SURAPA T, EKAWIT N. Automatic fall monitoring: a review [J]. **Sensors**, 2014, 14(7): 12900–12936.
- [61] IGUAL R, MEDRANO C, PLAZA I. Challenges, issues and trends in fall detection systems [J]. **Biomedical Engineering Online**, 2013, 12(1): 1–24.
- [62] DELAHOZ Y S, LABRADOR M A. Survey on fall detection and fall prevention using wearable and external sensors [J]. **Sensors**, 2014, 14(10): 19806–19842.
- [63] KOSHMAK G, LOUTFI A, LINDEN M. Challenges and issues in multisensor fusion approach for fall detection [J]. **Journal of Sensors**, 2016(2016): 6931789.